

# Ceph S3 - Placement Dynamique et Rétention Optimisée

Storage Classes, LUA et LifeCycle Policies

Frédéric Nass | Senior Ceph Engineer Octobre, 2025

### Content

O1. Classes de stockage
Placement targets & pools

**O2** . Placement dynamique LUA scripting

Rétention optimisée
LifeCycle Policies

**Démo**Écriture d'objets S3

### Classes de stockage

- Une ou plusieurs dans un stockage S3
- Associées à un modèle de placement de donnée : replication, erasure coding, compression
- Optimisent le placement des objets S3 en fonction de différents critères : performance, fréquence d'accès, durabilité, coûts
- Le client S3 peut indiquer la classe de stockage qu'il souhaite utiliser pour son objet

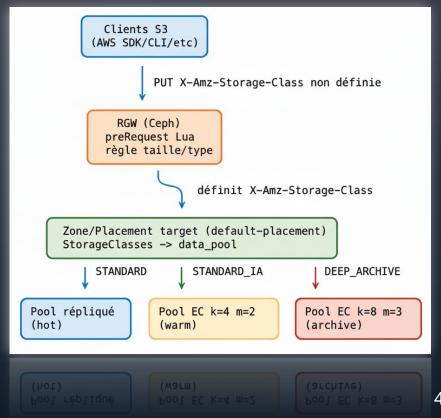
Mais il ne la précise pas toujours...

### Placement dynamique

...et si on le faisait à sa place ?

- Lorsque le client ne la précise pas
- Affecter automatiquement une classe de stockage à un objet en fonction :
  - du type d'objet (.mp4, .data, .pdf)
  - de la taille de l'objet (< 64kB, > 1MB)
  - du tenant (labo1, labo2)
  - du bucket (gros ou petits objets)
  - de la méthode d'upload (MPU ou pas)

L'efficience de stockage et la performance d'accès seraient assurées dès l'écriture des données



### Placement dynamique - LUA Scripting

- Les passerelles S3 peuvent exécuter des scripts LUA à la volée en fonction du contexte (prerequest, postrequest, background, getdata, putdata)
- Ces scripts LUA peuvent lire et modifier les métadonnées d'un objet avant de l'écrire
  - On peut donc dynamiquement définir ou modifier la classe de stockage d'un objet dès son écriture, selon certains critères

```
-- Règle: STORAGECLASS; PATTERN; OP; BYTES; BUCKET; TENANT; OVERRIDE
local function parse_rule(line, lineno)
 local parts = {}
  for field in string.gmatch(line, "([^;]+)") do parts[#parts+1] =
trim(field) end
  if #parts < 1 then return nil end
  local bytes_num, bytes_pretty = parse_size(parts[4] or "0")
  local r = 
   storage_class = parts[1] or "",
                  = (parts[2] ~= "" and parts[2]) or "*",
   pattern
                  = (parts[3] ~= "" and parts[3]) or "*",
   αo
   bytes
                  = bytes_num,
   bytes_str
                  = bytes_pretty,
                  = (parts[5] ~= "" and parts[5]) or "*",
    bucket
                  = (parts[6] ~= "" and parts[6]) or "*",
    tenant
   override
                  = to_bool(parts[7], false),
   lineno
                  = lineno
  if r.storage class == "" then return nil end
  return r
end
local function size_matches(op, threshold, content_len)
  if op == "*" then return true end
 if not content_len then return false end
  if op == "<" then return content_len < threshold end</pre>
  if op == "<=" then return content_len <= threshold end</pre>
  if op == ">" then return content_len > threshold end
  if op == ">=" then return content len >= threshold end
  if op == "=" then return content len == threshold end
  return false
end
```

docs.ceph.com/en/latest/radosgw/lua-scripting

### Rétention optimisée - Lifecycle Policies

- Les Lifecycle Policies assurent la transition d'objets S3 entre classes de stockage après un certain temps
- Les données les plus anciennes sont réécrites pour occuper moins de place dans le cluster

### La règle ci-contre :

- nettoie les MPU parts à 10 jours
- déplace les objets vers DEEP\_ARCHIVE mappée au pool EC 8+3 à 30 jours
- supprime les objets à 365 jours

```
"Rules": [
        "Filter": {
            "Prefix": ""
        "Status": "Enabled",
        "Transitions": [
                "Days": 30,
                "StorageClass": "DEEP_ARCHIVE"
        "AbortIncompleteMultipartUpload": {
            "DaysAfterInitiation": 10
        "Expiration": -{
            "Days": 365
        "ID": "double transition and expiration"
```

docs.ceph.com/en/latest/radosgw/lua-scripting

Placement dynamique et rétention optimisée

#### Creation des pools ceph

radosgw-admin period update --commit

```
ceph osd erasure-code-profile set ec42 k=4 m=2 ceph osd erasure-code-profile set ec83 k=8 m=3

ceph osd pool create s3.hot.data 256 256 replicated ceph osd pool create s3.warm.data 128 128 erasure ec42 ceph osd pool create s3.archive.data 64 64 erasure ec83

ceph osd pool application enable s3.hot.data rgw ceph osd pool application enable s3.warm.data rgw ceph osd pool application enable s3.archive.data rgw
```

#### Ajout des Storage Classes et Storage Class par défaut

```
radosgw-admin zonegroup placement add --rgw-zonegroup france
--placement-id default-placement --storage-class STANDARD_IA

radosgw-admin zonegroup placement add --rgw-zonegroup france
--placement-id default-placement --storage-class DEEP_ARCHIVE

radosgw-admin zonegroup placement default --rgw-zonegroup france
--placement-id default-placement --storage-class STANDARD_IA

radosgw-admin zonegroup get | grep default_placement
    "default_placement": "default-placement/STANDARD_IA"
```

#### Vérification

```
radosgw-admin zone placement list
        "kev": "default-placement",
        "val": {
            "index pool": "s3.buckets.index",
            "storage classes": {
                "DEEP ARCHIVE": {
                    "data pool": "s3.archive.data",
                    "compression type": "zstd"
                "STANDARD": {
                    "data pool": "s3.hot.data"
                "STANDARD IA": {
                    "data pool": "s3.warm.data",
                    "compression type": "lz4"
            "data extra pool": "s3.buckets.non-ec",
            "index type": 0,
            "inline data": true
```

Renseigner les data\_pool (et index/non-ec) côté zone

```
# STANDARD est déjà présente; s'assurer qu'elle pointe vers le pool répliqué "hot"
radosgw-admin zone placement add --rgw-zone nancy \
  --placement-id default-placement \
  --storage-class STANDARD \
  --data-pool s3.hot.data \
 --index-pool s3.buckets.index \
 --data-extra-pool s3.buckets.non-ec
# STANDARD IA -> EC 4+2
radosgw-admin zone placement add --rgw-zone nancy \
  --placement-id default-placement \
  --storage-class STANDARD IA \
  --data-pool s3.warm.data \
  --compression lz4
# DEEP ARCHIVE -> EC 8+3
radosgw-admin zone placement add --rgw-zone nancy \
  --placement-id default-placement \
  --storage-class DEEP_ARCHIVE \
  --data-pool s3.archive.data \
  --compression zstd
```

### Appliquer la configuration

```
radosgw-admin period update --commit
```

#### Modifier la configuration du service RGW

```
$ ceph orch ls --export --service_type=rgw --format yaml > rgw.yaml
$ vim rgw.yaml
service type: rgw
service id: monde-france-nancy
service name: rgw.monde-france-nancv
 rgw frontend port: 8080
 rgw realm: monde
 rgw_zone: nancy
 rgw zonegroup: france
custom_configs:
 - mount_path: /etc/ceph/rgw_storageclass_rules.conf
    content: |
      # Paramètres globaux MPU
      mpu default class=DEEP ARCHIVE
      mpu force=true
      # Paramètres globaux défaut non-MPU
      default class=STANDARD IA
      default force=false
      # Règles PUT objet (non-MPU)
      # STORAGECLASS; PATTERN; OP; BYTES; BUCKET; TENANT; OVERRIDE
      #STANDARD_IA;%.pdf;*;0;*;*;true
      #INTELLIGENT TIERING; *; <; 32768; bucket-logs; *; true
      #ONEZONE_IA;%.eml;*;0;*;tenant-a;false
      #GLACIER;%.iso;<;1073741824;media-bucket;*;true
      STANDARD; *; <=; 2MiB; *; *; true
      DEEP ARCHIVE; %.data; *; 0B; *; *; true
```

#### Appliquer la configuration et redéployer les RGWs

```
$ ceph orch apply -i rgw.yaml
Scheduled rgw.monde-france-metz update...
Scheduled rgw.monde-france-nancy update...
$ ceph orch redeploy rgw.monde-france-nancy
Scheduled to redeploy rgw.monde-france-nancy.r03h01.veyyjq on host 'r03h01'
```

#### Vérification

```
$ container id=$(ssh -n r03h01 podman ps | grep rgw | awk 'fprint $1?')
$ ssh -n r03h01 podman exec -it $container_id cat
/etc/ceph/rgw storageclass rules.conf
# Paramètres globaux MPU
mpu_default_class=DEEP_ARCHIVE
mpu force=true
# Paramètres globaux défaut non-MPU
default class=STANDARD IA
default_force=false
# Règles PUT objet (non-MPU)
# STORAGECLASS; PATTERN; OP; BYTES; BUCKET; TENANT; OVERRIDE
#STANDARD IA; %.pdf; *; 0; *; *; true
#INTELLIGENT TIERING; *; <; 32768; bucket-logs; *; true
#ONEZONE IA; %.eml; *; 0; *; tenant-a; false
#GLACIER; %. iso; <; 1073741824; media-bucket; *; true
STANDARD; *; <=; 2MiB; *; *; true
DEEP_ARCHIVE;%.data;*;0B;*;*;true
```

Téléchargement du script LUA github.com/frednass/s3-dynamic-placement-and-archiving

\$ curl -k -s https://raw.githubusercontent.com/frednass/s3-dynamic-placement-and-archiving/refs/heads/main/rgw\_storageclass\_rules.lua -o rgw\_storageclass\_rules.lua

#### Ajout du script LUA à la Rados Gateway (RGW)

\$ curl -k -s https://raw.githubusercontent.com/frednass/s3-dynamic-placement-and-archiving/refs/heads/main/rgw\_storageclass\_rules.lua -o rgw\_storageclass\_rules.lua

\$ radosgw-admin script put --infile=./rgw\_storageclass\_rules.lua --context=preRequest

### Application de la Lifecyle Policy S3

#### Création du bucket

```
$ rclone mkdir s3:/newbucket2
```

#### Créer la Lifecycle Policy

### Ajouter la Lifecycle Policy au bucket test

```
$ aws s3api put-bucket-lifecycle-configuration \
--endpoint http://10.38.1.59:8080 \
--bucket newbucket2 \
--lifecycle-configuration file://lifecycle.json
```

### Vérifier son application

### Application de la Lifecyle Policy S3

Vérifier sa prise en charge

Déclencher manuellement son exécution

### Vérification du placement dynamique

#### Augmenter le niveau de debug

```
$ ceph config set global debug_rgw 20
```

#### Surveiller les pools

```
Every 2.0s: rados df | grep -i -E 's3.*data|objects'; echo ----; ceph df | grep -i -E 'objects|s3.*data'
                                                                                                                           r01h01: Mon Sep 29 09:02:20 2025
                           USED OBJECTS CLONES COPIES MISSING_ON_PRIMARY UNFOUND DEGRADED
s3.archive.data
                                                                                                                                                       0 B
                                                                                                                                           0 B
                                                                                                                                                       0 B
s3.hot.data
s3.warm.data
P00L
                        ID PGS STORED OBJECTS
                                                     USED %USED MAX AVAIL
s3.hot.data
                            32
                                    0 B
                                                      0 B
                        25 32
s3.warm.data
                                    0 B
                                                      0 B
                                                                     74 GiB
s3.archive.data
```

#### Créer des objets de différentes taille de 16KiB à 4,7 MiB

```
for i in \{1..300\}; do dd if=/dev/urandom of=file_\{i\}.dd bs=16k count=\{i\}; done
```

### Pousser les objets vers S3

```
rclone sync . s3:/newbucket2 --s3-upload-cutoff 200M --s3-upload-concurrency 8
```

### Contrôle des Storage Classes associées aux objets S3

radosgw-admin bucket list --bucket newbucket2

### Vérification du placement dynamique

#### Journaux de la Rados Gateway (RGW)

• Objet de taille > à 2 MiB (4.7 MiB) se voit attribuer la SC par défaut STANDARD\_IA et le pool en EC 4+2

2025-09-29T06:45:21.783+0000 7fbc5lc28640 20 Lua INFO: Rule #1 (line 16) NO MATCH: obj='file\_288.dd' size=4718592 bucket='newbucket2' tenant='' reason=size op mismatch threshold=2mib
2025-09-29T06:45:21.783+0000 7fbc5lc28640 20 Lua INFO: Rule #2 (line 17) NO MATCH: obj='file\_288.dd' size=4718592 bucket='newbucket2' tenant='' reason=name pattern mismatch threshold=0b
2025-09-29T06:45:21.783+0000 7fbc5lc28640 20 Lua INFO: No rule applied: apply default StorageClass='STANDARD\_IA' (default\_force=false)

• Objet de taille < à 2 MiB (475 KiB) se voit attribuer la SC STANDARD et le pool en réplication x3

2025-09-29T06:45:21.806+0000 7fbb9babc640 20 Lua INFO: Rule #1 (line 16) MATCH -> apply StorageClass='STANDARD' (override=true) obj='file\_29.dd' size=475136 bucket='newbucket2' tenant='' threshold=2mib
2025-09-29T06:45:21.806+0000 7fbb9babc640 20 Lua INFO: Rule #2 (line 17) NO MATCH: obj='file\_29.dd' size=475136 bucket='newbucket2' tenant='' reason=name pattern mismatch threshold=0b
2025-09-29T06:45:21.806+0000 7fbb9babc640 20 Lua INFO: Rule #2 (line 17) NO MATCH: obj='file\_29.dd' size=475136 bucket='newbucket2' tenant='' reason=name pattern mismatch threshold=0b
2025-09-29T06:45:21.806+0000 7fbb9babc640 20 Lua INFO: Applied StorageClass='STANDARD' to object 'file\_29.dd'

• Objet envoyé en multipart upload (MPU) déposé directement dans les archives

2025-09-29T07:46:38.837+0000 7fbbac2dd640 20 Lua INFO: MPU initiate: apply default StorageClass='DEEP\_ARCHIVE' (force=true)

### Vérification de la rétention optimisée

Observer le remplissage des différents pools

```
r01h01: Mon Sep 29 09:05:01 2025
Every 2.0s: rados df | grep -i -E 's3.*data|objects'; echo ----; ceph df | grep -i -E 'objects|s3.*data'
POOL NAME
                            USED OBJECTS CLONES COPIES MISSING ON PRIMARY UNFOUND DEGRADED
s3.archive.data
                             0 B
                                                                                                      5781
                                                                                                                0 B
                                                           1257 MiB
s3.hot.data
                         387 MiB
                                      128
                                                  84
                                                                                                    137169 1.7 GiB
                                                                                                                       288625
                                                                                                                               4.2 GiB
                                                                                                                                              0 B
                                                                                                                                                           0 B
s3.warm.data
                                      346
                                                                                                                                                           0 B
P00L
                                   STORED
                                           OBJECTS
                                                      USED
                                                             %USED MAX AVAIL
                                  129 MiB
                                               128
                                                    387 MiB
                                                             0.35
s3.hot.data
s3.warm.data
                                  580 MiB
                                               346
                                                   870 MiB
                                                             0.77
                                                                       73 GiB
s3.archive.data
                                      0 B
                                                       0 B
                                                                       79 GiB
```

Réduire le temps entre chaque exécution

\$ ceph config set global rgw\_lc\_debug\_interval 1

Exécuter la Lifecycle Policy

\$ radosgw-admin lc process

Nouveau contrôle (à 30s + radosgw-admin gc process --include-all)

```
Every 2.0s: rados df | grep -i -E 's3.*data|objects'; echo ----; ceph df | grep -i -E 'objects|s3.*data'
                                                                                                                               r01h01: Mon Sep 29 09:06:27 2025
POOL NAME
                                                  COPIES MISSING ON PRIMARY
                                                                                                                                   WR USED COMPR
                            USED OBJECTS CLONES
                                                                             UNFOUND
                                                                                                                RD
s3.archive.data
                         978 MiB
                                                                                                     5905
                                                                                                           113 MiB
                                                                                                                       18192
                                                                                                                              13 GiB
                                                                                                                                                          0 B
                                                          978 MiB
s3.hot.data
                                                                                            0
                                                                                                          1.8 GiB
                                                                                                                                                          0 B
s3.warm.data
                                      300
                                                   1800
                                                                                                                                             ΘR
                                                                                                                                                          0 B
P00L
                         ID PGS
                                   STORED
                                           OBJECTS
                                                      USED
                                                            %USED MAX AVAIL
s3.hot.data
                              32
                                     0 B
                                                       0 B
                                                                      36 GiB
s3.warm.data
                                     0 B
                                               300
                                                       0 B
                                                                0
                                                                      73 GiB
s3.archive.data
                             32 711 MiB
                                                   978 MiB
                                                             0.87
                                                                      80 GiB
```

Nouveau contrôle (à 365s + radosgw-admin gc process --include-all) → les pools sont vides

### Vérification de la rétention optimisée

Journaux de la Rados Gateway (RGW)

Transition à 15 et Expiration à 30 pour les tests

Objet déposé 2025-09-29T08:12:56.866+0000 7fbc34bee640 1 beast: 0x7fbb4f01e6f0: 10.38.1.55 - fred [29/Sep/2025:08:12:56.842 +0000] "PUT /newbucket2/file\_98.dd?x-id=Put0bject HTTP/1.1" 200 1605632 - "rclone/v1.71.1" - latency=0.023999780s 2025-09-29T08:12:56.869+0000 7fbbf7373640 1 beast: 0x7fbb4f01e6f0: 10.38.1.55 - fred [29/Sep/2025:08:12:56.867 +0000] "HEAD /newbucket2/file 98.dd HTTP/1.1" 200 0 -"rclone/v1.71.1" - latency=0.000999991s Objet transitionné vers la Storage Class DEEP ARCHIVE 2025-09-29T08:13:11.052+0000 7fbc5bc5d640 20 lifecycle: operator()(): key=file\_98.ddwp\_thrd: 2, 0 2025-09-29T08:13:11.052+0000 7fbc5bc5d640 20 lifecycle: obj has expired(): mtime=2025-09-29T08:12:56.861730+0000 days=30 base time=2025-09-29T08:13:11.053797+0000 timediff=15.0538 cmp=30 is expired=0 2025-09-29T08:13:11.052+0000 7fbc5bc5d640 20 lifecycle: check(): key=file\_98.dd: is\_expired=0 wp\_thrd: 2, 0 2025-09-29T08:13:11.052+0000 7fbc5bc5d640 20 lifecycle: obj\_has\_expired(): mtime=2025-09-29T08:12:56.861730+0000 days=15 base\_time=2025-09-29T08:13:11.053827+0000 timediff=15.0538 cmp=15 is expired=1 2025-09-29T08:13:11.052+0000 7fbc5bc5d640 20 lifecycle: check(): key=file 98.dd: is expired=1 wp thrd: 2, 02025-09-29T08:09:24.627+0000 7fbc5ac5b640 2 lifecycle: TRANSITIONED::newbucket2[f50809af-d67e-426c-bccd-78f8ff6af983.1788835.1]):file\_98.dd -> DEEP\_ARCHIVE wp\_thrd: 2, 2 Objet supprimé 2025-09-29T08:13:26.005+0000 7fbc5d460640 20 lifecycle: operator()(): key=file 98.ddwp thrd: 1, 1 2025-09-29T08:13:26.005+0000 7fbc5d460640 20 lifecycle: obj has expired(): mtime=2025-09-29T08:12:56.861730+0000 days=30 base time=2025-09-29T08:13:26.005972+0000 timediff=30.006 cmp=30 is expired=1 2025-09-29T08:13:26.005+0000 7fbc5d460640 20 lifecycle: check(): key=file\_98.dd: is\_expired=1 wp\_thrd: 1, 1 2025-09-29T08:13:26.005+0000 7fbc5d460640 20 lifecycle: obj has expired(): mtime=2025-09-29T08:12:56.861730+0000 days=15 base time=2025-09-29T08:13:26.005992+0000 timediff=30.006 cmp=15 is expired=1 2025-09-29T08:13:26.005+0000 7fbc5d460640 20 lifecycle: check(): key=file\_98.dd: is\_expired=1 wp\_thrd: 1, 1 2025-09-29T08:09:39.524+0000 7fbc5b45c640 2 lifecycle: DELETED::newbucket2[f50809af-d67e-426c-bccd-78f8ff6af983.1788835.1]):file 98.dd wp thrd: 2, 1



## Merci!

Questions ?

Frédéric Nass

frederic.nass@clyso.com